杨金果

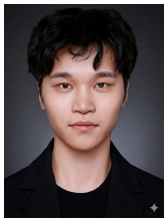

电话 15523408645 ｜ **邮箱** : hsjdu9522@gmail.com ｜ 个人博客:http://124.221.186.145 ｜ | github: https://github.com/yjg-djb |

个人概述

逻辑清晰，具有解决问题的能力，善于学习钻研。熟悉 Multi-Agent ，熟悉智能问答，场景陪练，智能问数，上下文工程，数据集构建，模型微调等应用具有银行场景通过 AI 赋能提效的实际工作经验。

核心技能与掌握技术栈

- 掌握核心语言 Python (PyTorch, TensorFlow, FastAPI), SQL, Shell；
- 掌握 LangGraph, LangChain, MCP,Skill 开发等,掌握 Dify,Flowsie，N8n 等智能体平台的编排，api 集成二开，RPA 流程自动化，Text2SQL,Function Calling，上下文工程等。
- 熟悉 Rag 流程，熟悉数据流水线，结构化等，Rag 优化，熟悉 Elasticsearch,Milvus 等向量数据库。
- 熟悉主流大模型（包括但不限于 gpt，qwen,deepseek）架构等。
- 熟悉大模型全链路微调（数据清洗，分块，预训练，监督微调，RLHF，PPO）；
- 推理与部署：了解 vLLM，SGLang ，模型量化 , Docker/K8s 等
- 前端与桌面开发：React 18, Electron 40, Redux Toolkit, Tailwind CSS

工作经历

中科聚信科技（北京）有限公司 **大模型研发工程师** 2025.03-2026.02

工作背景： 落地 AI 应用，针对银行 **1.2 万**员工做银行内部提效，主要方向是新员工培训，流程审批、报表生成，报告生成，制度业务类资料查询。

工作内容：处理非结构化复杂数据，引入视觉版式解决 PDF 双栏排版问题达到 **90%，**对表格进行重构，降低向量模型对行列交叉关系的感知脆弱问题提升财报类咨询准确率 **25%，**结合 graphrag 提升对制度条理类知识提高 **15%**准确率。

融合传统 Pipeline 架构的稳定与 LLM 驱动，使用 langgrph,Flow 定义和对话栈等结合 mcp 工具对接数据库等构建出可供业务人员自助创建自动化任务的智能对话系统，人力成本降低 **60%。**

结合 tts，qa 对，上下文工程等构建场景陪练,生成培训课程，知识点，问题等。

收集业务 case 针对制度解释错误，业务营销技巧过去总结等问题进行 qwen3-8b 模型微调对齐提升制度，营销技巧回答准确率百分之 **20%**

科大讯飞股份有限公司 **大模型研发工程师（实习）** 2024.10-2025.02

工作内容:技术调研，清洗数据，数据抽样，训练垂直领域大模型，支持诊断建议、病历生成与患者问答。

技术实现：增量预训练：基于 Deepseek-r1-7B，在 20G 中文医学文献上继续训练，使用 Deepspeed ZeRO-3 + FlashAttention，训练效率提升 **40%。**

有监督微调 (SFT)：构建 **20 万条**医患对话数据集，设计多任务 Prompt 模板（分类/生成/摘要），微调后诊疗建议准确率提升至 **88%。**

RLHF & DPO 优化：奖励模型：基于 Pairwise Ranking Loss 训练，结合安全性和有用性。

接入 RAG：减少模型幻觉和知识更新滞后问题，目前做到几乎无幻觉。

实现 PPO 强化学习与 PPO 对齐策略：人工评估胜率较基线模型提高 **62%。**

项目经历

基于多模态大模型的移动端自主智能体

技术栈: Python, PyTorch, GLM-4V-9B, vLLM, ADB, LangChain, ChromaDB, Docker

目标：基于 Open-AutoGLM 架构，构建通过自然语言指令自主操控 Android 手机的智能体系统，完成推理引擎重构、记忆系统设计等核心模块开发。

推理引擎重构: 将 HuggingFace 管道迁移至 vLLM 异步架构，引入 PagedAttention 解决显存碎片，端到端延迟从 **8s** 降至 **2.5s/step**

吞吐优化: 设计动态 Batching 与请求批处理队列，实现单卡并发吞吐量 **3** 倍提升

记忆增强架构(MobileRAG): 设计双重校验机制，记忆命中时直接复用历史动作序列，Token 消耗降低 **60%**

轨迹记忆系统: 定义 Trajectory Schema，基于 ChromaDB 构建向量索引，支持相似任务检索

系统稳定性设计: 基于感知哈希实现死循环检测，通过 ROI 汉明距离识别界面停滞，实现分级自愈机制，长程任务完成率提升 **40%**

基于 openclaw 的桌面智能体系统深度研究

技术栈: TypeScript, React 18, Electron 40, Claude Agent SDK, SQLite, QEMU

目标：解决 openclaw 权限不可控问题，解决布在服务器不能访问本地文件的问题，增加必要 skill,支持自我进化等技能，支持多平台（飞书）接入

架构深度分析: 研究龙虾（openclaw）的 Electron 严格进程隔离架构，分析 40+ IPC 通道设计、Context Isolation 安全策略及主进程/渲染进程通信机制

安全机制验证: 深入沙箱执行系统，基于 QEMU+Alpine Linux 实现虚拟机隔离，验证环境变量限制、工作区边界、权限门控等 5 层安全防护体系

技能系统研究: 分析 16+内置技能（文档处理、Web 自动化、视频生成等）的热插拔架构，研究基于 XML 的自动路由和依赖管理策略

数据与记忆系统: 研究 SQLite 7 表存储架构，实现基于 SHA1 指纹的记忆去重和三级置信度管理，支持 12 条记忆/会话的智能注入

多平台集成: 分析钉钉、飞书等 6 种 IM 网关集成，验证手机远程触发→Cowork 执行的完整控制链路，支持自然语言定时任务创建

教育背景

2023.9-2025.6 **重庆对外经贸学院** **物联网工程(专升本)**

综合排名：9/120（专业前 10%） **职务**：班长、数学建模组学生组组长

荣誉奖励：一次 2025 年优秀大学毕业生、**一次**国家奖学金、2024 年全国大学生数学建模竞赛**国家二等奖**、2024 年蓝桥杯程序设计大赛**省级二等奖**、2024 年“互联网+”大学生创新创业大赛市级**银奖、作孚**奖学金、重庆市创业创新赛事市级奖项**若干**（2024-2025）；

2020.9-2023.6 **重庆城市职业学院** **大数据技术与应用(科大讯飞联培)(专科)**

综合排名: 3/259(专业前 1%) **职务：** 学习委员

荣誉奖励：一次 2023 年优秀大学毕业生、**两次**国家奖学金、**两次**校一等奖学金 2022、2023 年全国大学生数学建模竞赛**省级一等奖**、2022 高教社杯数学建模竞赛**省级一等奖**